Metodología ETL y modelo de datos

Caso práctico Analista de Operación nivel III · Leonardo Soto Berrío

Herramientas

Python (pandas) para la extracción y transformación (script etl_caso_practico.py, incluido en la carpeta) y Tableau Public para el modelo y el tablero. Usé Python para el ETL porque así cada paso queda escrito y se puede volver a correr si llegan datos nuevos.

1. Extracción

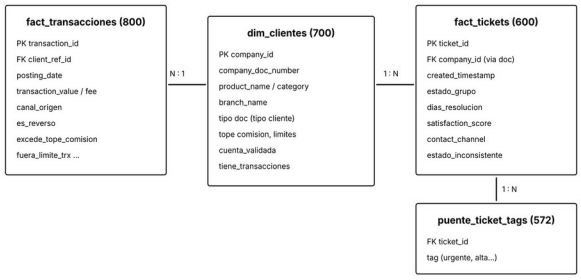
Fuente	Formato	Registros	Cómo se leyó
clientes_productos	CSV (coma)	700	Documentos y cuentas como texto, no como número
transacciones	TXT (separador |)	800	Separador "|", documento y teléfono como texto
tickets_usuarios	JSON anidado	600	Aplané form_details; tags (lista) a tabla aparte

2. Transformaciones

- Tipos de dato: fechas a formato fecha y documentos como texto (son identificadores, no se suman).
- Datos sensibles: quité número de cuenta bancaria, documento del titular y teléfono porque no aportan al análisis.
- canal_origen: limpié el texto "Origen:API" y quedó solo API, POS o Web.
- estado_grupo en tickets: open y pending = Pendiente; closed y solved = Resuelto.
- dias_resolucion: diferencia entre creación y cierre, solo para tickets resueltos que tienen fecha de cierre (234). No la calculé para los pendientes con fecha de cierre porque no sé si esa fecha es real.
- Banderas de control en transacciones, cruzando con las condiciones del contrato del comercio: excede_tope_comision, valor_sobre_tope, fuera_limite_trx, antes_de_vinculacion, abono_cuenta_no_validada y reverso_inconsistente.
- Banderas en tickets: estado_inconsistente, tiene_encuesta, es_urgente y rango_resolucion (0–3, 4–7, 8–14 y más de 14 días).
- En clientes: tiene_transacciones, para identificar comercios vinculados que no han transado.

3. Carga y modelo

Dejé un modelo tipo estrella con el comercio en el centro, porque las dos preguntas grandes del caso (cómo transaccionan y qué problemas tienen) giran alrededor de él.



- **dim_clientes**: una fila por comercio (company_id), con producto, sucursal, tipo de documento y condiciones del contrato.
- **fact_transacciones**: se relaciona con clientes por client_ref_id = company_id.
- **fact_tickets**: el JSON no trae el id del comercio, solo el documento. En el ETL le pegué company_id cruzando client_doc_number con company_doc_number, para que las dos tablas de hechos usen la misma llave.
- **puente_ticket_tags**: un ticket puede tener varios tags. Si los dejaba en la misma tabla se duplicaban tickets y se inflaban los conteos.
- Para el tablero en Tableau Public (versión web) cargué dos vistas planas que salen de este modelo: transacciones y tickets, cada una ya con los atributos del comercio (producto, sucursal, tipo de cliente). Lo hice así porque la versión web maneja mejor una fuente por archivo; el modelo de fondo es el mismo.
- Para las fechas usé la jerarquía de fechas de Tableau (año, trimestre, mes) en lugar de una tabla calendario aparte, porque el volumen es pequeño.

4. Validaciones y supuestos

- El 100% de transacciones y tickets cruza con un comercio. No hay ids duplicados ni filas repetidas.
- El IVA es exactamente el 19% de la comisión en todas las transacciones, así que ese cálculo está bien.
- **Supuesto principal:** interpreté max_commission_value como la comisión máxima por transacción debido al porcentaje, el mínimo y el máximo que se puede encontrar en el contrato y representa una práctica común para los pagos. Lo que se nota aquí es el hecho de que la comisión cobrada es exactamente el porcentaje del valor y no se recorta en el máximo. Si ese campo representa algún otro significado como el límite mensual entonces el resultado cambia y esa es la razón por la que se dejó la advertencia para la validación.
- **Supuesto:** en tickets tomé el estado como la verdad y no la fecha de cierre. Puede que esa fecha sea una fecha compromiso y no el cierre real; eso lo validaría con el equipo.
- **Decisión:** para medir reversos usé reversal_flag y no transaction_info, porque es el campo que parece sistémico. La diferencia entre los dos la dejé marcada como hallazgo.
- Los segmentos (canal, producto, sucursal, tipo de documento) son muy similares. Así es como los estoy representando sin hacer distinciones que no sean hechas por los datos.